

Optimisations des SGBDR

Étude de cas : MySQL

Introduction

Pourquoi optimiser son application ?

Introduction

Pourquoi optimiser son application ?

1. Gestion de gros volumes de données
2. Application critique (finance, ...)
3. Gagner des clients (Amazon, ...)

Introduction

Où faut-il optimiser son application ?

Introduction

Où faut il optimiser son application ?

Identifier et optimiser les *bottlenecks* !

1. CPU
2. I / O (disque, réseau, ...)
3. Allocation mémoire

Introduction

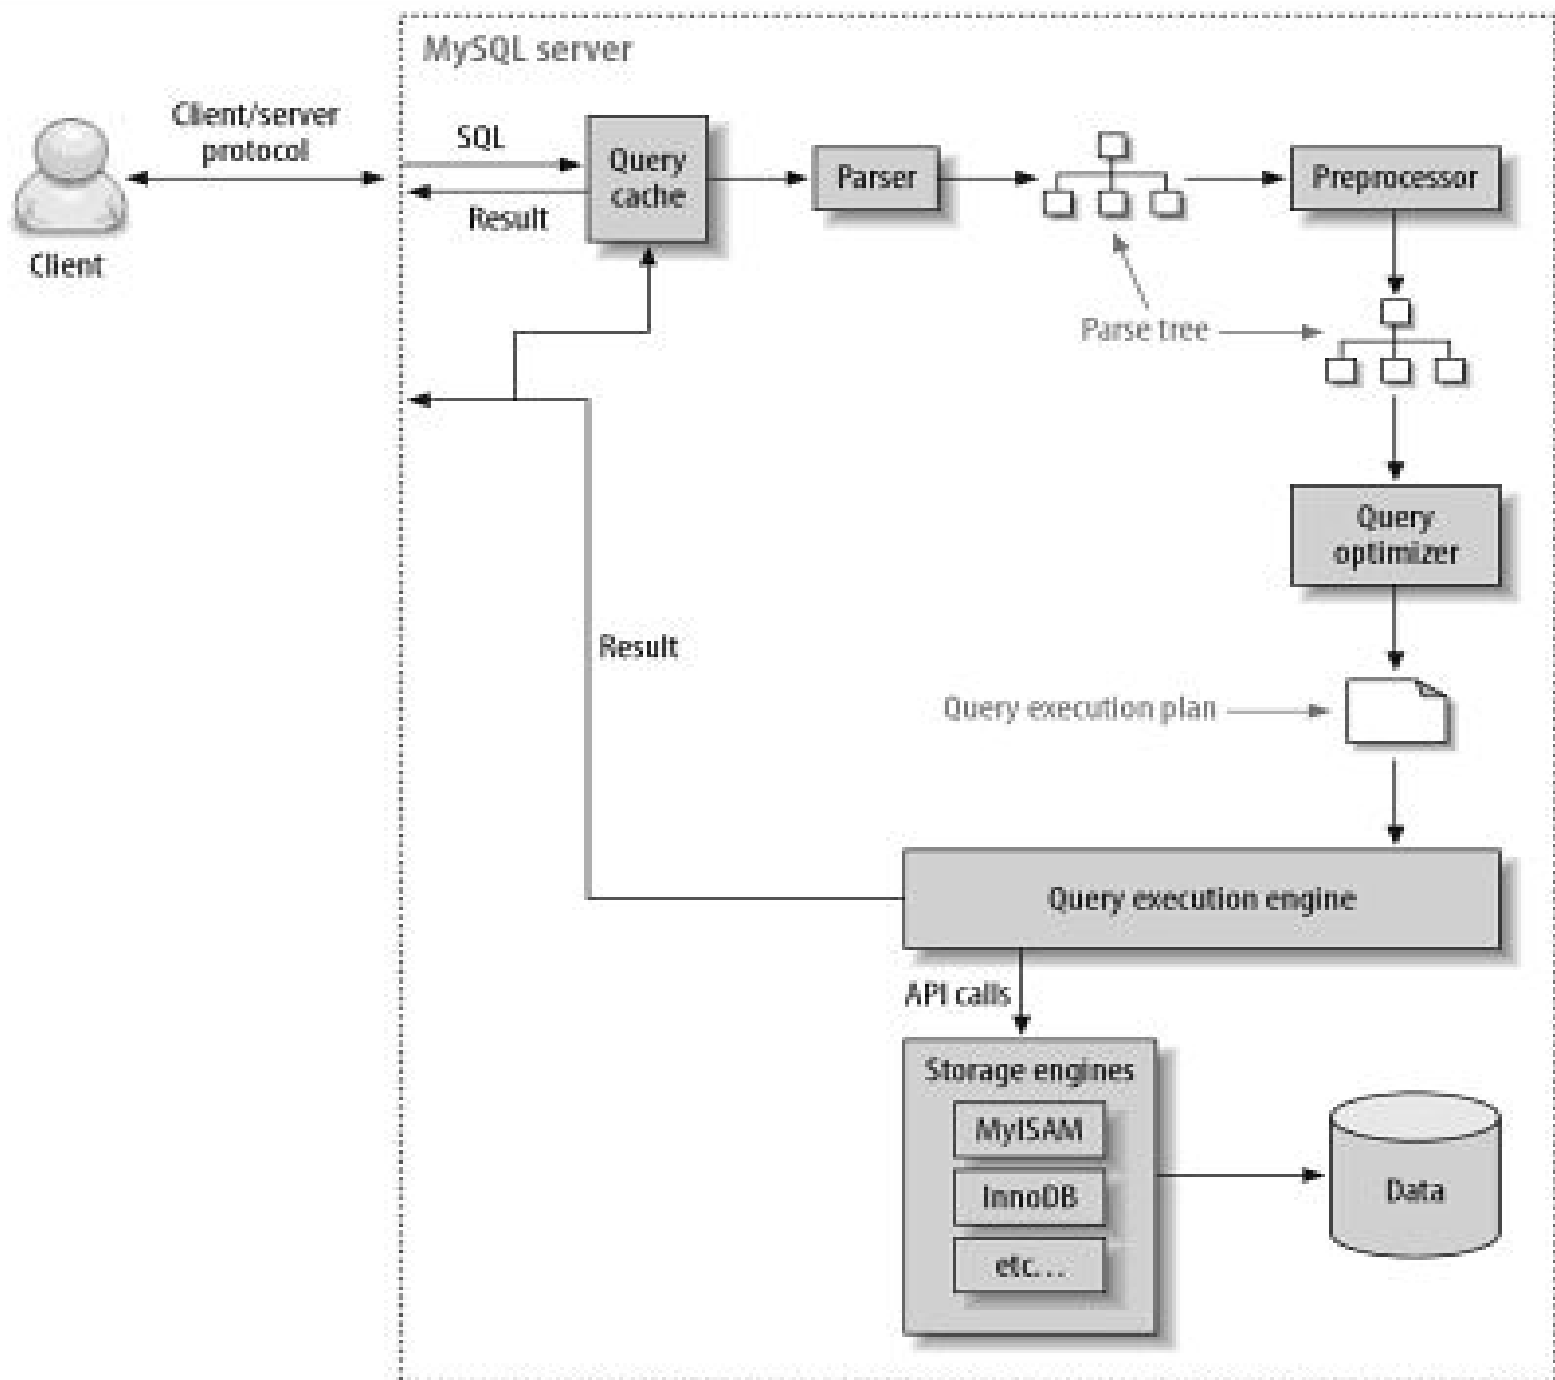
Un SGBDR utilise toutes ces ressources de manière intensive.

Il devient donc le *bottleneck* !

De manière générale, il faut améliorer sa base avant d'améliorer son application.

Optimisations

1. Architecture
2. Moteurs de stockage
3. Index
4. Types de données
5. Performances et requêtes



Moteurs de stockage

MyISAM, InnoDB, Archive

Moteurs de stockage

Un moteur de stockage est un ensemble d'algorithmes permettant de gérer une table d'une base de données.

Chaque moteur a une vocation, un objectif, est une réponse à une problématique.

Choisir le bon moteur de stockage change de manière drastique les performances.

Moteurs de stockage

Les plus populaires sont :

- MyISAM
- InnoDB
- Archive
- Memory

MyISAM

Ancien moteur par défaut.

Fonctionnalités : Non transactionnel,
réparation manuelle et automatique, écriture
de clés différées, compression, ...

Mais se veut en partie transactionnel...

InnoDB

Transactionnel : MVCC, niveaux d'isolation, row-level locking, ...

Predictable read, performances énormes pour les requêtes sur clés primaires, ...

Chaque modification de table provoque sa reconstruction complète !

Réputé pour être plus lent que MyISAM

Archive

Ne supporte que les insertions / sélections.

Les lignes sont compressées et les écritures placées dans un buffer.

Row-level locking (pourquoi ?)

En bref : optimisé pour les insertions et l'espace disque.

Indexation

B-Tree et hash

Indexation

Quel est l'intérêt d'indexer ses données ?

Indexation

Quel est l'intérêt d'indexer ses données ?

Les performances !

Un index permet de retrouver très rapidement un ensemble de données.


B-Tree

Arbre équilibré

Avantages : Lecture séquentielle rapide - Accès très rapides

Inconvénients : Potentielle mauvaise localité - Taille de l'index pouvant être importante

B-Tree



Hachage

Création d'une clé associée à une valeur ou un groupe.

Avantages : Très rapide pour les insertions / suppressions / sélections avec égalité.

Inconvénients : Sélections ordonnées

Indexation

Choisir son index :

```
CREATE INDEX id_index ON lookup (id) USING BTREE;
```

```
CREATE INDEX id_index ON lookup (id) USING HASH;
```

Par défaut, le B-Tree est utilisé.

Types de données

Types de données

Qu'apporte le bon choix du type de données ?

Types de données

Qu'apporte le bon choix du type de données ?

Moins d'espace disque, de mémoire, de cycles CPU et d'espace dans le cache du CPU.

Les entiers

TINYINT, SMALLINT, MEDIUMINT, INT, BIGINT codé respectivement sur 8, 16, 24, 32, 64 bits.

Peuvent être non signés (mot-clé UNSIGNED)

Quelles sont les différences entre INT(1) et INT(24) ?

Le texte

Les implémentations des CHAR et VARCHAR varient avec le moteur de stockage.

CHAR : Taille fixe

VARCHAR : Taille variable

VARCHAR

Seul le nécessaire est persisté.

Utilise entre 1 et 2 bytes pour stocker la taille.

L'action associée au dépassement varie avec le moteur de stockage.

CHAR

Les espaces en fin de chaîne sont supprimés.

Des espaces sont ajoutés à la fin pour la comparaison.

Efficace lorsque la taille est prédéfinie ou très faible.

NULL

Eviter NULL dès que possible !

Ajoute 1 byte par entrée.

Rend les index et les comparaisons plus complexes, donc l'optimisation des requêtes.

Performances et requêtes

Requêtes SQL et cache

Performances et requêtes

Récupérer plus de données que nécessaire.

MySQL ne renvoie pas progressivement les lignes, mais un ResultSet complet !

Comment réduire le nombre de lignes récupérées sans WHERE ?

Performances et requêtes

Récupérer toutes les colonnes lors d'une jointure multiple.

Abuser du `SELECT *` est un crime !

Pourquoi ne pas simplement récupérer les colonnes qui nous intéressent ?

Performances et requêtes

Utiliser des requêtes préparées.

La requête n'est parsée et optimisée qu'une seule fois. Utilisation d'un protocole unique pour l'envoi des paramètres.

Propre à une connexion, inutile si appelée une seule fois, attention au leak !

Performances et requêtes

Compresser les données à travers le réseau.

Via le shell : `--compress`

Via JDBC : `<db_name>?useCompression=true`

Performances et requêtes

Plein de requêtes VS requêtes complexes.

MySQL a été pensé pour gérer rapidement les petites requêtes.

Penser au cache ...

Performances et requêtes

MySQL met en cache les requêtes de sélection.

Attention aux requêtes ne pouvant être mises en cache ! (NOW, CURRENT_DATE).

Cache entièrement paramétrable

Performances et requêtes

Lors de la réception d'une requête, si celle-ci commence par "SEL", on regarde le cache.

Comment s'effectue la recherche dans le cache ?

Est-ce toujours pertinent d'utiliser le cache ?

Performances et requêtes

`SQL_CACHE / SQL_NO_CACHE` : Force la requête à être mise en cache, ou non.

`EXPLAIN` : Renvoie les informations sur le plan d'exécution

`DESCRIBE` : Décrit une table d'une base de données

Conclusion

L'optimisation d'une application commence par son SGBD !

MySQL est un produit complet et souple grâce à ses moteurs de stockage.

Utilisé par les grands du Web (Twitter, Facebook, ...)